

The ML/AI Model Canvas		DESIGNED FOR	DESIGNED BY	DATE	VERSION	
MACHINE LEARNING · CHURN PREDICTION		Operadora de Telecomunicações	João · Jayne · Bianca Emi	04/05/2026	1.0	
BUSINESS DRIVERS		ACCEPTABLE ACCURACY & TRADE-OFFS		DATA TYPE / SPEED / SIZE	INFRASTRUCTURE	GOAL
PROBLEMA DE NEGÓCIO A operadora apresenta alta taxa de churn mensal, impactando negativamente a receita recorrente (MRR) e aumentando o custo de aquisição de clientes (CAC).		DECISÃO Priorizar alto recall para a classe de churn.		TIPO Dados tabulares estruturados com variáveis demográficas, serviços contratados, comportamento e informações financeiras.	Ambiente versionado com gerenciamento de dependências, experimentação e testes automatizados.	DATA SCIENCE Desenvolver modelo de classificação de churn otimizado para atingir recall > 70%, precisão > 60% e AUC > 80%.
STAKEHOLDERS - Diretoria (definição de metas e ROI) - Marketing/CRM (execução de campanhas de retenção) - Customer Success (intervenção direta junto a clientes em risco) - Equipe de Dados (desenvolvimento, validação e manutenção do modelo)		FALSO NEGATIVO — ALTO RISCO Alto risco: clientes em churn não identificados pelo modelo, resultando em perda direta de receita futura.		VOLUME Dataset com ≥ 5.000 registros e ≥ 10 variáveis (escalável para milhões em produção).	Uso de MLflow para tracking de experimentos, métricas e artefatos.	NEGÓCIO - Reduzir churn em 10% no próximo semestre - Gerar aumento incremental de receita (~US\$ 14.000/mês)
MÉTRICAS DE NEGÓCIO KPI: Churn Rate Financeiro: LTV (Lifetime Value) Eficiência: Taxa de Conversão da Intervenção ROI: Custo de Churn Evitado		FALSO POSITIVO — RISCO MÉDIO Risco médio: clientes sem churn sendo tratados como risco, gerando ações desnecessárias e aumento de custos.		VELOCIDADE Inferência near real-time via API, integrada a sistemas de CRM.	Pipeline containerizado com Docker, modelo exposto via API REST para inferência.	TÉCNICO Implementar pipeline end-to-end reprodutível com versionamento, validação e monitoramento contínuo das métricas (recall, precisão, AUC) em produção.
PERGUNTAS DE NEGÓCIO - Qual o churn atual? - Quanto custa perder um cliente? - Quanto clientes podemos abordar por mês? - Qual o tempo de antecedência ideal?		MÉTRICAS TÉCNICAS - AUC-ROC (separabilidade) - PR-AUC (desbalanceamento) - Recall (principal métrica de negócio) - F1-score (equilíbrio)				AVANÇADO Aplicar cost-sensitive learning e ajuste de threshold para otimizar o trade-off entre recall e precisão, garantindo AUC > 80%.
		PREMISSAS - Comportamento passado é preditivo de churn futuro - Dados disponíveis representam adequadamente os clientes - Ações de retenção impactam a decisão do cliente				
UPSTREAM		CURRENT TEAM		MODEL TYPE	INTERVENTION	
FONTE DE DADOS Dataset Telco Customer Churn (IBM)		João Data Scientist	Jayne Data Scientist	MODELO PRINCIPAL Rede Neural Multicamadas (MLP) com PyTorch	AÇÃO Predições alimentam CRM para acionar estratégias de retenção em clientes de alto risco.	
		Bianca Emi Data Engineer		BASELINES - DummyClassifier - Regressão Logística	ESTRATÉGIAS - Ofertas personalizadas - Contato ativo - Atendimento prioritário	
					CRITÉRIO DE ATIVAÇÃO Threshold de risco (ex: churn > 0.7)	
UPSTREAM		DOWNSTREAM				
PRÉ-PROCESSAMENTO - Limpeza de dados - Feature engineering - Codificação de variáveis categóricas - Normalização - Pipeline com Scikit-learn		ENTREGA VIA API Modelo disponibilizado via API REST (FastAPI) retornando probabilidade de churn e classificação.		MONITORAMENTO Monitoramento contínuo com métricas e alertas - Performance (AUC, Recall) - Data drift - Concept drift		
				RE-TREINAMENTO Re-treinamento periódico (ex: mensal) ou baseado em degradação de performance		
Tech Challenge · Fase 1 · MLE PÓS João · Jayne · Bianca Emi		PYTORCH · SKIKIT-LEARN · MLFLOW · FASTAPI		ML Canvas Churn Prediction Pipeline		